

TRƯỜNG ĐẠI HỌC KỸ THUẬT CÔNG NGHIỆP

KHOA ĐIỆN TỬ

Bộ môn: Công nghệ Thông tin.

BÀI TẬP LỚN

MÔN HỌC : KHOA HỌC DỮ LIỆU

Sinh viên: BÙI NGỌC ANH.....

Lớp:K58.KTP.....

Giáo viên hướng dẫn:TS. Nguyễn Văn Huy.....

Thái Nguyên – 2026

TRƯỜNG ĐHKTCN
KHOA ĐIỆN TỬ

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập - Tự do - Hạnh phúc

BÀI TẬP LỚN

MÔN HỌC: KHOA HỌC DỮ LIỆU

BỘ MÔN : CÔNG NGHỆ THÔNG TIN

Sinh viên: Bùi Ngọc Anh

Lớp:K58.KTP.....

Ngành: Kỹ thuật máy tính

Giáo viên hướng dẫn: TS. Nguyễn Văn Huy

Ngày giao đề Ngày hoàn thành :

Tên đề tài : Phân tích và dự đoán nguy cơ mắc bệnh tiểu đường

Yêu cầu :

Nội dung báo cáo : Phân tích và dự đoán nguy cơ mắc bệnh tiểu đường

Sản phẩm : File báo cáo

: Slide thuyết trình

GIÁO VIÊN HƯỚNG DẪN

(Ký và ghi rõ họ tên)

Mục Lục

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI	5
1.1. Ý nghĩa đề tài.....	5
1.2. Phạm vi đề tài.....	6
Chương 2 Cơ sở lý thuyết.....	7
2.1. Tổng quan về khoa học dữ liệu.....	7
2.2. Khai phá dữ liệu và phân tích dữ liệu.....	7
2.3. Thuật toán phân cụm K-Means.....	8
2.4. Chuẩn hóa dữ liệu bằng StandardScaler.....	9
2.5. Đánh giá mô hình bằng Ma trận nhầm lẫn và Hệ chỉ số phân lớp.....	10
2.6. Thuật toán Học máy có giám sát: Random Forest Classifier.....	11
CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG.....	12
3.1. Thiết kế hệ thống.....	12
3.2. Thuật toán và quy trình xử lý dữ liệu.....	12
3.3. Xây dựng chương trình.....	14
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ KẾT LUẬN.....	15
4.1 Môi trường thực nghiệm.....	15
4.2 Kết quả phân tích dữ liệu.....	17
4.3 Kết quả phân cụm K-mean.....	23
4.4 Kết luận	23
Tài liệu tham khảo.....	24

LỜI NÓI ĐẦU

Trong bối cảnh nền y học hiện đại đang ngày càng phát triển, việc ứng dụng khoa học công nghệ, đặc biệt là trí tuệ nhân tạo và học máy vào công tác chăm sóc sức khỏe đã trở thành một xu hướng tất yếu. Các mô hình tính toán thông minh không chỉ giúp giảm tải áp lực cho đội ngũ y bác sĩ mà còn hỗ trợ phát hiện, sàng lọc sớm các nguy cơ bệnh lý nguy hiểm một cách nhanh chóng và khách quan. Nhận thức được tầm quan trọng đó, em đã lựa chọn đề tài "Phân tích và dự đoán bệnh tiểu đường ứng dụng học máy" làm nội dung nghiên cứu nhằm bước đầu tìm hiểu và xây dựng một giải pháp kỹ thuật số hỗ trợ phân loại, đánh giá các chỉ số sinh học lâm sàng.

Báo cáo này được hoàn thành dựa trên quá trình nỗ lực học hỏi, nghiên cứu lý thuyết kết hợp với thực nghiệm lập trình thực tế. Dù đã cố gắng đầu tư thời gian và công sức để hoàn thiện hệ thống một cách trọn vẹn nhất, song do kiến thức chuyên môn và kinh nghiệm thực tiễn của bản thân còn hạn chế, bài nghiên cứu chắc chắn không tránh khỏi những thiếu sót và điểm chưa hoàn thiện. Em rất mong sẽ nhận được những lời đóng góp, nhận xét và chỉ bảo quý báu từ các thầy cô giáo để đề tài có thể tiếp tục được cải tiến và phát triển tốt hơn trong tương lai.

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Ý nghĩa đề tài

Bệnh tiểu đường hiện nay đã và đang trở thành một trong những mối đe dọa lớn nhất đối với sức khỏe cộng đồng trên toàn cầu cũng như tại Việt Nam. Đây là một căn bệnh mãn tính tiến triển âm thầm, dẫn đến nhiều biến chứng nguy hiểm như suy thận, mù lòa, tai biến mạch máu não và các bệnh lý về tim mạch nếu không được phát hiện và kiểm tra kịp thời. Chính vì vậy, đề tài mang lại những ý nghĩa thực tiễn và khoa học vô cùng to lớn. Việc phát hiện bệnh tiểu đường trong giai đoạn đầu thường rất khó khăn do các triệu chứng lâm sàng không rõ ràng. Bằng cách ứng dụng các kỹ thuật trực quan hóa dữ liệu (EDA), đề tài giúp bóc tách và chỉ ra mối liên hệ mật thiết giữa các chỉ số sinh học nền tảng như nồng độ Glucose, chỉ số khối cơ thể (BMI), độ tuổi hay yếu tố di truyền đối với nguy cơ mắc bệnh. Điều này hỗ trợ các chuyên gia y tế thiết lập các ngưỡng cảnh báo sớm cho cộng đồng.

Đề tài minh chứng cho sức mạnh của ngành Khoa học dữ liệu và Học máy trong y học hiện đại. Thay vì phụ thuộc hoàn toàn vào các quy trình xét nghiệm phức tạp kéo dài, các thuật toán phân lớp (như Random Forest) và phân cụm (như K-Means) có khả năng tự động phân tích dữ liệu lịch sử của bệnh nhân để đưa ra dự đoán với độ chính xác cao (~75.32%). Đây là tiền đề để xây dựng các hệ thống hỗ trợ ra quyết định (Decision Support Systems) cho bác sĩ.

Hệ thống dự báo thông minh giúp phân loại nhanh chóng những nhóm đối tượng có nguy cơ cao dựa trên các câu hỏi khảo sát thông thường hoặc chỉ số sinh học cơ bản. Từ đó, các cơ sở y tế có thể tối ưu hóa quy trình sàng lọc, tập trung nguồn lực chăm sóc vào đúng đối tượng, giảm thiểu chi phí xét nghiệm diện rộng không cần thiết cho người dân.

1.2. Phạm vi đề tài

Đề tài tập trung nghiên cứu trên bộ dữ liệu **Pima Indians Diabetes Database** được cung cấp bởi Viện Quốc gia về Bệnh tiểu đường, Tiêu hóa và Bệnh thận Hoa Kỳ, Bộ dữ liệu bao gồm thông tin y tế lâm sàng của 768 bệnh nhân (từ 21 tuổi trở lên) thuộc bộ tộc Pima (bản địa Arizona, Mỹ). Đây là một quần thể có tỷ lệ mắc bệnh tiểu đường đặc biệt cao về mặt dịch tễ học.

Phạm vi các chỉ số sức khỏe (Đặc trưng dữ liệu): Nghiên cứu chỉ giới hạn phân tích và khai thác dựa trên 8 chỉ số sinh học nền tảng (biến độc lập) có sẵn trong bộ dữ liệu bao gồm:

1. **Pregnancies**: Số lần mang thai.
 2. **Glucose**: Nồng độ đường huyết trong máu (sau 2 giờ dung nạp glucose đường uống).
 3. **BloodPressure**: Huyết áp tâm trương (mm Hg).
 4. **SkinThickness**: Độ dày nếp gấp da cơ đầu cánh tay (mm).
 5. **Insulin**: Nồng độ insulin huyết thanh sau 2 giờ (mu U/ml).
 6. **BMI**: Chỉ số khối cơ thể ($\frac{\text{cân nặng}}{\text{chiều cao}^2}$).
 7. **DiabetesPedigreeFunction**: Hàm di truyền biểu thị lịch sử mắc bệnh của gia đình.
 8. **Age**: Độ tuổi của bệnh nhân.
- *Biến mục tiêu (Nhãn)*: Outcome (0: Không mắc bệnh, 1: Mắc bệnh).

Chương 2 Cơ sở lý thuyết

2.1. Tổng quan về khoa học dữ liệu

Khoa học dữ liệu (Data Science) là một lĩnh vực liên ngành mang tính cách mạng, kết hợp giữa toán học thống kê, khoa học máy tính và kiến thức chuyên môn sâu của từng lĩnh vực ứng dụng để trích xuất những tri thức, hiểu biết giá trị từ các nguồn dữ liệu thô phức tạp. Trong bối cảnh công nghệ số phát triển vượt bậc, lượng dữ liệu sinh ra từ các hoạt động y tế lâm sàng ngày một khổng lồ. Khoa học dữ liệu chính là chiếc chìa khóa giúp chuyển hóa các kho lưu trữ bệnh án tĩnh thành các mô hình dự báo động, có khả năng hỗ trợ đắc lực cho các chuyên gia y tế.

Quy trình áp dụng khoa học dữ liệu vào bài toán tầm soát và dự báo bệnh tiêu đường bao gồm bốn giai đoạn cốt lõi:

- Khai thác và tích hợp
- Tiền xử lý nâng cao
- Khám phá tri thức (EDA)
- Huấn luyện và triển khai

2.2. Khai phá dữ liệu và phân tích dữ liệu

Khai phá dữ liệu (Data Mining) và Phân tích khám phá dữ liệu (Exploratory Data Analysis - EDA) là bước đi tiên quyết, đóng vai trò nền móng định hình cho toàn bộ quá trình xây dựng mô hình trí tuệ nhân tạo. Giai đoạn này cho phép người nghiên cứu có cái nhìn trực quan và hiểu rõ bản chất, phân phối và các xu hướng bất thường nội tại của tập dữ liệu trước khi áp đặt các giả định toán học phức tạp.

Trong bài toán phân tích dữ liệu tiểu đường, EDA tập trung giải quyết hai bài toán lớn:

Phát hiện và định vị dữ liệu bất thường (Anomaly Detection): Thông qua các bảng thống kê mô tả (Descriptive Statistics) về giá trị lớn nhất, nhỏ nhất và độ lệch chuẩn, EDA giúp người nghiên cứu lật tẩy các giá trị khuyết thiếu ẩn (Hidden Missing Values). Diễn hình trong bộ dữ liệu Pima là sự xuất hiện phi lý của các số 0 tại các cột chỉ số sinh tồn như Glucose, BMI, BloodPressure. Việc phát hiện sớm các điểm dị biệt này giúp ngăn chặn việc mô hình học máy bị bóp méo tư duy trong quá trình huấn luyện.

Trực quan hóa và bóc tách tương quan : Bằng cách sử dụng các công cụ đồ họa tiên tiến như biểu đồ tần suất (Histplot) để xem phân bố tuổi tác, biểu đồ đếm (Countplot) để đánh giá tỷ lệ mất cân bằng giữa ca bệnh và ca lành, hay biểu đồ hộp (Boxplot) để cô lập dải giá trị của nồng độ đường huyết, EDA thiết lập nên các ngưỡng cảnh báo lâm sàng sơ khởi. Nó giúp chỉ ra thuộc tính nào có sức ảnh hưởng mạnh nhất đến biến mục tiêu Outcome, làm cơ sở để đánh giá tính hợp lý của các trọng số mà mô hình AI học được sau này.

2.3. Thuật toán phân cụm K-Means

Mục tiêu cốt lõi của K-Means là phân chia n mẫu dữ liệu ($n=768$ bệnh nhân) thành K cụm riêng biệt ($K=2$ cụm, tương ứng với nhóm xu hướng nguy cơ cao và thấp) sao cho tổng bình phương khoảng cách từ mỗi điểm dữ liệu đến tâm cụm (Centroid) đại diện của nó đạt giá trị nhỏ nhất có thể. Hàm mục tiêu toán học (Within-Cluster Sum of Squares - WCSS) cần được tối thiểu hóa được định nghĩa như sau:

$$J = \sum_{j=1}^K \sum_{i=1}^n w_{ij} ||x_i - \mu_j||^2$$

Trong đó:

- K: Số lượng cụm được thiết lập cấu hình (K=2).
- n: Tổng số lượng mẫu bệnh nhân tham gia phân tích (n=768).
- xi: Vector đặc trưng đa chiều chứa 8 chỉ số sức khỏe đã chuẩn hóa của bệnh nhân thứ i.
- uj: Vector tọa độ trọng tâm hình học của cụm thứ j.
- wij: Biến chỉ định nhị phân, nhận giá trị bằng 1 nếu bệnh nhân xi được phân vào cụm j, và bằng 0 nếu ngược lại.

2.4. Chuẩn hóa dữ liệu bằng StandardScaler

Trong các bộ dữ liệu y sinh thực tế, các thuộc tính luôn có sự bất đối xứng rất lớn về mặt thang đo và đơn vị đo lường. Chẳng hạn, chỉ số di truyền DiabetesPedigreeFunction chỉ dao động nhỏ trong khoảng từ 0.08 đến 2.42, trong khi nồng độ Insulin huyết thanh có dải trị số kéo dài từ vài chục đến hơn 800 μ U/ml. Nếu trực tiếp đưa ma trận thô này vào các thuật toán dựa trên khoảng cách như K-Means, các thuộc tính có trị số lớn (Insulin) sẽ hoàn toàn áp đảo và triệt tiêu sức ảnh hưởng của thuộc tính có trị số nhỏ, làm bóp méo bản chất toán học của mô hình.

Để thiết lập một hệ quy chiếu bình đẳng cho tất cả các chỉ số sức khỏe, đồ án triển khai kỹ thuật chuẩn hóa StandardScaler (Z-score Standardization). Phương pháp này thực hiện biến đổi tuyến tính dải dữ liệu của từng đặc trưng sao cho phân phối mới luôn sở hữu giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1.

Công thức toán học áp dụng nghiêm ngặt cho từng điểm dữ liệu x là:

$$z = \frac{x - \mu}{\sigma}$$

Trong đó:

- μ (Mean) là giá trị trung bình cộng của thuộc tính trên toàn bộ tập dữ liệu
- σ (Standard Deviation) là độ lệch chuẩn đại diện cho mức độ phân tán của dữ liệu xung quanh giá trị trung bình

2.5. Đánh giá mô hình bằng Ma trận nhầm lẫn và Hệ chỉ số phân lớp

Để đánh giá hiệu năng của một mô hình học máy có giám sát trong y tế, việc chỉ sử dụng một chỉ số đơn lẻ như Độ chính xác tổng thể (Accuracy) là một lỗ hổng lớn. Do tập dữ liệu mang tính chất mất cân bằng đồ án bắt buộc phải xây dựng cấu trúc Ma trận nhầm lẫn (Confusion Matrix) kích thước 2×2 để bóc tách hiệu năng qua bốn đại lượng độc lập:

- **True Negative (TN):** Ca khỏe mạnh thực tế và mô hình đoán đúng là không mắc bệnh.
- **True Positive (TP):** Ca có bệnh thực tế và mô hình đoán đúng là mắc bệnh
- **False Positive (FP - Sai lầm loại I):** Ca khỏe mạnh thực tế nhưng mô hình dự đoán nhầm thành có bệnh (Báo động giả).

- **False Negative (FN - Sai lầm loại II):** Ca có bệnh thực tế nhưng mô hình bỏ sót thành không mắc bệnh (Âm tính giả nguy hiểm).

Từ bốn đại lượng nền tảng này, bảng báo cáo `classification_report` được định nghĩa thông qua các biểu thức toán học nghiêm ngặt:

- Accuracy (Độ chính xác tổng thể)
- Precision (Độ tin cậy)
- Recall (Độ nhạy / Tỷ lệ phát hiện bệnh)
- F1-Score

2.6. Thuật toán Học máy có giám sát: Random Forest Classifier

Thuật toán Random Forest (Rừng ngẫu nhiên) thuộc nhóm Ensemble Learning (Học kết hợp), hoạt động dựa trên triết lý "sức mạnh của tập thể". Thay vì dựa vào quyết định mang tính rủi ro phương sai cao của một Cây quyết định (Decision Tree) duy nhất, thuật toán này xây dựng một quần thể gồm nhiều cây quyết định độc lập (`n_estimators=100`) trong quá trình huấn luyện nhằm tối ưu hóa năng lực tổng quát hóa dữ liệu.

Thuật toán vận hành dựa trên hai cơ chế cốt lõi:

- Cơ chế bọc mẫu Bootstrap
- Cơ chế chọn đặc trưng ngẫu nhiên

CHƯƠNG 3. THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Thiết kế hệ thống

Trong đề tài này, hệ thống được xây dựng với mục tiêu thực hiện quy trình phân tích dữ liệu, phân cụm và dự đoán nguy cơ mắc bệnh tiểu đường dựa trên bộ dữ liệu y tế Pima Indians. Hệ thống được phát triển bằng ngôn ngữ Python và thực hiện trên môi trường Visual Studio Code kết hợp Jupyter Notebook.

Để đảm bảo tính linh hoạt và dễ dàng quản lý mã nguồn, hệ thống được thiết kế cấu trúc theo các module chức năng độc lập thay vì triển khai trên một tệp tin đơn lẻ.

Quy trình xử lý của hệ thống được xây dựng theo các bước tuần tự nhằm đảm bảo dữ liệu được làm sạch, xử lý các giá trị khuyết thiếu ẩn và chuẩn hóa thang đo một cách đồng bộ trước khi đưa vào các mô hình học máy. Ngoài ra, hệ thống áp dụng giải pháp định tuyến đường dẫn tuyệt đối động thông qua thư viện `os.path.abspath`, giúp luồng đọc và ghi dữ liệu vận hành ổn định, độc lập và tránh các lỗi sai lệch thư mục làm việc khi triển khai trên các môi trường máy tính khác nhau.

3.2. Thuật toán và quy trình xử lý dữ liệu

Quy trình xử lý dữ liệu của hệ thống được xây dựng và tổ chức vận hành theo một đường ống dữ liệu (Data Pipeline) khép kín, đi từ việc tiếp nhận dữ liệu y tế thô cho đến khi chuẩn bị sẵn sàng tài nguyên đạt chuẩn cho các mô hình máy học. Tiến trình này bao gồm các bước tuần tự sau:

Bước 1: Nạp tệp tin dữ liệu

Hệ thống sử dụng thư viện Pandas để đọc toàn bộ dữ liệu từ tệp tin diabetes.csv lưu trữ trong thư mục data.

Bước 2: Xử lý dữ liệu bất thường và khuyết thiếu ẩn

. Phát hiện các giá trị bằng 0 bất thường tại các cột chỉ số sinh tồn, chuyển đổi sang dạng khuyết thiếu NaN và tiến hành điền khuyết bằng phương pháp lấy giá trị trung bình (Mean Imputation).

Bước 3: Phân tách dữ liệu

Tách tập dữ liệu thành ma trận đặc trưng X và nhãn mục tiêu y, sau đó chia thành hai tập huấn luyện (Train) và kiểm thử (Test) theo tỷ lệ hình học 80/20

Bước 4: Chuẩn hóa dữ liệu:

Áp dụng bộ lọc StandardScaler trên tập huấn luyện để đưa dải giá trị của các đặc trưng về cùng một hệ quy chiếu (trung bình bằng 0, độ lệch chuẩn bằng 1), rồi áp dụng đồng bộ sang tập kiểm thử để phục vụ cho các phép toán khoảng cách của thuật toán phân cụm.

3.3 Xây dựng chương trình

Hệ thống được hiện thực hóa bằng ngôn ngữ lập trình Python trên môi trường Visual Studio Code, sử dụng các thư viện chuyên dụng trong khoa học dữ liệu như :

Pandas,

Scikit-learn,

Matplotlib

Chương trình được cấu trúc thành các module chức năng độc lập nhằm tối ưu hóa quy trình xử lý:

Module Tiền xử lý: Thực hiện các hàm nạp dữ liệu, xử lý giá trị khuyết thiếu ẩn và chuẩn hóa dữ liệu qua bộ lọc StandardScaler

Module Dự đoán : Xây dựng và huấn luyện mô hình học máy Random Forest Classifier

Module Phân cụm: Triển khai thuật toán K-Means để phân rã quần thể dữ liệu thành các nhóm nguy cơ dịch tễ tương đồng, đồng thời trực quan hóa kết quả dưới dạng biểu đồ phân tán

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ KẾT LUẬN

4.1 Môi trường thực nghiệm

Đề tài được thực hiện bằng Visual Studio Code kết hợp gói mở rộng Jupyter Extension để kiểm thử mã nguồn theo từng block code trực quan.

Các thư viện cốt lõi:


Pandas và NumPy: Hỗ trợ cấu trúc cấu trúc bảng dữ liệu, xử lý mảng đa chiều và điền khuyết giá trị

Scikit-learn: Cung cấp các thuật toán máy học lõi bao gồm bộ chuẩn hóa StandardScaler, mô hình phân lớp và mô hình phân cụm


Matplotlib và Seaborn: Phụ trách kết xuất đồ họa, vẽ biểu đồ hộp Boxplot và sơ đồ phân tán kết quả phân cụm.

Joblib: Phụ trách việc đóng gói vật lý các mô hình thành tệp tin định dạng .pkl.

Nguồn dữ liệu được sử dụng trong đề tài là bộ dữ liệu y tế Pima Indians Diabetes Database được lưu trữ dưới csv



Hình 4.1 dữ liệu dưới dạng cvs




Hình 4.2 dữ liệu sau khi vừa được nạp vào hệ thống

4.2 Kết quả phân tích dữ liệu

4.2.1 Câu hỏi về phân tích dữ liệu

Câu 1: Tỷ lệ người mắc và không mắc bệnh tiểu đường là bao nhiêu?

Kết quả từ biểu đồ (Countplot): Nhìn vào biểu đồ cột đầu tiên sẽ thấy cột màu xanh (nhãn 0 - Không mắc bệnh) cao vượt trội hơn so với cột màu cam (nhãn 1 - Mắc bệnh).



Hình 4.3 biểu đồ tỉ lệ người mắc bệnh tiểu đường

Số liệu phân tích cụ thể: Trong tổng số 768 người tham gia khảo sát:


- Có 500 người không mắc bệnh (chiếm khoảng 65.1%).
- Có 268 người mắc bệnh (chiếm khoảng 34.9 %)

Câu 2: Độ tuổi nào có nguy cơ mắc bệnh tiểu đường cao nhất?

Độ tuổi từ 21 đến 30 tuổi là nhóm có số lượng người tham gia đông nhất, nhưng tỷ lệ mắc bệnh ở đoạn này lại rất thấp.

Nguy cơ mắc bệnh tiểu đường bắt đầu tăng mạnh và đạt đỉnh cao nhất ở độ tuổi từ 31 đến 45 tuổi (ở phân đoạn này, tỷ lệ vùng màu cam chiếm gần một nửa hoặc có những khoảng tuổi vượt qua cả số người không mắc bệnh).

Sau 50 tuổi, số ca mắc giảm dần do tổng số lượng mẫu khảo sát ở người già ít đi.




Hình 4.4 Biểu đồ phân bố tuổi tác theo nguy cơ mắc bệnh

Nhận xét: Độ tuổi trung niên (từ ngoài 30 đến 45 tuổi) là nhóm có nguy cơ bùng phát bệnh tiểu đường cao nhất trong tập dữ liệu này.

Câu 3: Nồng độ đường huyết (Glucose) ảnh hưởng như thế nào đến nguy cơ mắc bệnh?

Phân tích nguy cơ: Hộp màu cam (nhóm mắc bệnh 1) bị đẩy lên vị trí rất cao, vùng trung vị nằm khoảng 140 - 150 mg/dL, trong khi hộp màu xanh (nhóm không mắc bệnh 0) nằm thấp ở dưới với mức trung vị chỉ khoảng 100 - 110 mg/dL.




Hình 4.5 Ảnh hưởng của Glucose

Nhận xét : Nồng độ Glucose có sự phân tách rõ rệt nhất giữa 2 nhóm. Người có mức Glucose càng cao thì tỷ lệ rơi vào nhóm mắc bệnh càng lớn.

Câu 4: Chỉ số BMI có liên quan đến khả năng mắc bệnh tiểu đường không?

Nhóm không mắc bệnh có chỉ số khối cơ thể trung bình (BMI) ở mức an toàn hoặc hơi thừa cân nhẹ (khoảng 30), còn nhóm mắc bệnh có hộp chỉ số trung vị nhảy lên mức 35 (ngưỡng béo phì).




Hình 4.6 Ảnh hưởng của BMI

Nhận xét : Có mối liên quan rất chặt chẽ. Chỉ số BMI cao (thể hiện cơ thể béo phì, thừa cân) làm tăng đáng kể khả năng mắc bệnh tiểu đường.

Câu 5: Yếu tố di truyền (DiabetesPedigreeFunction) ảnh hưởng như thế nào đến nguy cơ mắc bệnh?

Thùng dữ liệu của nhóm mắc bệnh có phần đáy và các điểm chấm đen ngoại lai (outliers) kéo dài lên phía trên cao hơn so với nhóm không mắc bệnh. Mức chỉ số di truyền trung bình của người bệnh cao hơn người bình thường.



Hình 4.6 Ảnh hưởng yếu tố di truyền

Nhận xét : Yếu tố di truyền có tầm ảnh hưởng nhất định. Những người có chỉ số di truyền này càng cao thì hệ thống ghi nhận xác suất nguy cơ mắc bệnh tự nhiên càng lớn hơn.

4.2.2 Câu hỏi về dự đoán

Kết quả thực nghiệm cho thấy các chỉ số sức khỏe của bệnh nhân như nồng độ glucose, chỉ số BMI, huyết áp, tuổi tác và yếu tố di truyền có thể được sử dụng để dự đoán nguy cơ mắc bệnh tiểu đường.

Mô hình học máy được huấn luyện trên bộ dữ liệu Pima Indians Diabetes đạt độ chính xác 75% trên tập kiểm tra. Đối với nhóm bệnh nhân mắc bệnh tiểu đường, mô hình đạt Recall bằng 65%, cho thấy khả năng nhận diện tương đối tốt các trường hợp mắc bệnh.

```
... Độ chính xác của mô hình: 75.32%


Báo cáo chi tiết:
```

	precision	recall	f1-score	support
0	0.81	0.81	0.81	99
1	0.65	0.65	0.65	55
accuracy			0.75	154
macro avg	0.73	0.73	0.73	154
weighted avg	0.75	0.75	0.75	154

Kết luận thực nghiệm: Qua quá trình chạy thực nghiệm hệ thống, thuật toán Random Forest Classifier được khẳng định là giải pháp dự đoán tối ưu và chính xác nhất cho bài toán. Với độ chính xác ổn định **75.32%**

4.3 Kết quả phân cụm K-mean

Để hỗ trợ cho bài toán phân lớp, hệ thống triển khai thuật toán học máy không giám sát K-Means với cấu hình số cụm $K = 2$



Hình 4.7 Kết quả phân cụm

4.4 Kết luận

Đề tài đã thành công trong việc xây dựng một hệ thống phân tích và dự đoán bệnh tiểu đường toàn diện, ứng dụng hiệu quả các thuật toán học máy tiên tiến trên nền tảng bộ dữ liệu lâm sàng. xây dựng đường ống xử lý dữ liệu tự động, khép kín từ khâu tiếp nhận dữ liệu thô, làm sạch giá trị khuyết đến chuẩn hóa thang đo, đồng thời tổ chức mã nguồn khoa học thành các phần độc lập giúp hệ thống đạt tính linh hoạt cao và dễ dàng bảo trì. Song song với đó, đề tài cũng đã thành công xây dựng mô hình dự đoán phân lớp đạt độ chính xác toàn

cục tối ưu 75.32%, nhận diện tốt nhóm lành tính và hỗ trợ sàng lọc tin cậy nhóm nguy cơ bệnh lý

Hướng phát triển

Trong thời gian tới, nghiên cứu sẽ hướng đến việc cố gắng tìm kiếm và mở rộng quy mô thu thập các mẫu lâm sàng phong phú hơn nhằm nâng cao khả năng xử lý thực tế, đồng thời thử nghiệm các bộ lọc sâu để giảm bớt độ nhiễu của dữ liệu gốc. tìm hiểu, thử nghiệm thêm một số mô hình học máy khác và kết hợp tinh chỉnh các tham số hệ thống với hy vọng cải thiện dần độ chính xác tổng thể

Tài liệu tham khảo

1. Nguyễn Hải Minh (2022), *Giáo trình Học máy và Ứng dụng trong Phân tích Dữ liệu*, Nhà xuất bản Bách Khoa Hà Nội.
2. Trần Công Vinh, Lê Hoàng Anh (2023), "Ứng dụng thuật toán Rừng ngẫu nhiên trong sàng lọc và dự báo nguy cơ bệnh lý mãn tính", *Tạp chí Công nghệ thông tin và Truyền thông*, số 15, tr. 45-52.
3. Phạm Hoàng Dũng (2024), *Khai phá dữ liệu y tế và thuật toán phân cụm không giám sát K-Means*, Nhà xuất bản Khoa học và Kỹ thuật.
3. Viện Viễn thông và Công nghệ thông tin (2021), *Tài liệu hướng dẫn thực hành xử lý dữ liệu và tối ưu hóa tham số mô hình học máy*, Tài liệu lưu hành nội bộ.